

PROPOSAL PENELITIAN

APLIKASI YOLOv11 PADA SISTEM PELAPORAN KERUSAKAN JALAN BERBASIS WEB

Oleh:

Arya Maulana Suryakartadireja

065122081



**PROGRAM STUDI ILMU KOMPUTER
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS PAKUAN
BOGOR
2026**

HALAMAN PENGESAHAN

Judul : Aplikasi Yolov11 Pada Sistem Pelaporan Kerusakan Jalan Berbasis Web
Nama : Arya Maulana Suryakartadireja
NPM : 065122081

Mengesahkan,

Pembimbing Pendamping
Program Studi Ilmu Komputer
FMIPA – UNPAK

Pembimbing Utama
Program Studi Ilmu Komputer
FMIPA – UNPAK

Yusma Yanti, M.Si.

Arie Qur'ania, M. Kom.

Mengetahui,

Ketua Program Studi Ilmu Komputer
FMIPA – UNPAK

Dekan
FMIPA – UNPAK

Dr. Fajar Delli Wihartiko, S.Si., M.M., M.Kom.

Asep Denih, S.Kom., M.Sc., Ph.D.

KATA PENGANTAR

Puji syukur penulis panjatkan atas kehadiran Allah SWT yang telah memberikan rahmat dan petunjuk, sehingga penulis dapat menyelesaikan proposal penelitian ini yang berjudul “**Aplikasi Yolov11 Pada Sistem Pelaporan Kerusakan Jalan Berbasis Web**” Dalam penulisan laporan ini, penulis dengan senang hati ingin mengucapkan terima kasih yang sebesar-besarnya kepada:

1. Arie Qur'ania, M.Kom., selaku Pembimbing Utama yang telah memberikan bimbingan, arahan, dorongan moril, serta motivasi kepada penulis selama proses penyusunan tugas akhir ini.
2. Yusma Yanti, M.Si., selaku Pembimbing Pendamping yang telah memberikan bimbingan, arahan, semangat, dan motivasi kepada penulis.
3. Dr. Fajar Delli Wihartiko, S.Si., M.M., M.Kom., selaku ketua Program Studi Ilmu Komputer FMIPA Universitas Pakuan Bogor.
4. Kepada kedua orang tua penulis yang selalu memberikan kasih sayang, doa, dukungan, serta pengorbanan yang tiada henti kepada penulis. Terima kasih atas segala perhatian, semangat, dan kepercayaan yang diberikan.
5. Om Aldi, Om Anton, Om Bagja, Om Yoga, Om Caca, Bunda Tina, Tante Endang, Tante Ayu, Tante Ika, Tante Echa, dan Tante Mira, yang selalu memberikan doa, dukungan, semangat, serta perhatian kepada penulis selama proses penyusunan tugas akhir ini.
6. Kekasih yang sudah setia menemani penulis, Khori Aulia Ria Anggraeni, yang selalu kebersamaian penulis sejak hari pertama kuliah hingga saat ini. Terima kasih atas dukungan, tawa, dan kebersamaan yang tak ternilai. Kehadiranmu telah menjadi penyemangat dalam setiap langkah perjalanan ini.
7. Adik-adik penulis, yaitu Edsel, Kinarian, Senja, Alesha, Inara, Risyad, Desvika, Tatjana, Maudy, Luthfiyah, Athar, dan Arka, yang selalu menghibur dan menjadi penyemangat penulis selama proses penyusunan tugas akhir ini
8. Teman-Teman penulis, Alif, Agam, Ariiq, Faqih, Fauzi, Naufal dan Alfandi yang telah banyak membantu penulis untuk bisa berada di titik ini.

Penulis menyadari bahwa proposal penelitian ini masih memiliki keterbatasan dan memerlukan penyempurnaan. Oleh karena itu, penulis sangat mengharapkan kritik dan saran yang bersifat membangun guna penyempurnaan penelitian ke depannya. Semoga proposal ini dapat menjadi dasar pelaksanaan penelitian yang bermanfaat bagi pengembangan ilmu pengetahuan dan penerapan teknologi di bidang infrastruktur jalan.

Bogor, Maret 2026

Arya Maulana Suryakartadireja

065122081

DAFTAR ISI

HALAMAN PENGESAHAN	i
KATA PENGANTAR	ii
DAFTAR ISI	iii
DAFTAR GAMBAR	iv
DAFTAR TABEL	v
DAFTAR LAMPIRAN	vi
BAB I PENDAHULUAN	1
1.1 Latar Belakang.....	1
1.2 Tujuan Penelitian.....	2
1.3 Ruang Lingkup Penelitian.....	2
1.4 Manfaat Penelitian.....	2
BAB II LANDASAN TEORI	3
2.1 Tinjauan Pustaka.....	3
2.1.1 Kerusakan Kondisi Jalan.....	3
2.1.2 <i>Road Damage Score</i> (RDS).....	3
2.1.3 Pengolahan Citra Digital.....	5
2.1.4 <i>Deep Learning</i>	5
2.1.5 Computer Vision.....	5
2.1.6 Deteksi Objek.....	5
2.1.7 Algoritma YOLO (<i>You Only Look Once</i>).....	5
2.1.8 Arsitektur <i>You Only Look Once</i> (YOLOv11).....	6
2.1.9 Evaluasi Model <i>You Only Look Once</i> (YOLO).....	8
2.1.10 Sistem Monitoring Berbasis <i>Website</i>	9
2.2 Penelitian Terdahulu.....	9
2.3 Perbandingan Terdahulu.....	11
BAB III METODE PENELITIAN	12
3.1 Metode Penelitian.....	12
3.1.1 Perencanaan.....	12
3.1.2 Studi literatur.....	13
3.1.3 Metode <i>Knowledge Discovery in Database</i> (KDD).....	13
3.1.4 Tahap Analisis Sistem.....	18
3.1.5 Tahap Desain Sistem.....	19
3.1.6 Tahap Implementasi.....	20
BAB IV TATA LAKSANA PENELITIAN	21
4.1 Waktu dan Tempat Penelitian.....	21
4.1.1 Waktu Penelitian.....	21
4.1.2 Tempat Penelitian.....	21
4.2 Jadwal Penelitian.....	21
4.3 Alat dan Bahan Penelitian.....	21
4.3.1 Alat Penelitian.....	21
4.3.2 Bahan Penelitian.....	21
DAFTAR PUSTAKA	22
LAMPIRAN	25

DAFTAR GAMBAR

Gambar 1. Kerusakan Jalan	3
Gambar 2. Arsitektur YOLOv11	7
Gambar 3. Alur Penelitian	12
Gambar 4. <i>Dataset</i> Kerusakan Jalan.....	14
Gambar 5. Arsitektur YOLOv11 untuk Deteksi Objek	16
Gambar 6. Visualisasi <i>Confusion Matrix</i> Model YOLOv11	17
Gambar 7. <i>Flowchart</i> Sistem.....	20

DAFTAR TABEL

Tabel 1. Perbandingan Terdahulu	11
Tabel 2. Diagram SLR	11
Tabel 3. Distribusi Anotasi Dataset per Kelas	14
Tabel 4. Tranformasi data	15
Tabel 5. Spesifikasi Model YOLOv11.	16
Tabel 6. Komponen Arsitektur YOLOv11	16
Tabel 7. Hasil evaluasi YOLOv11 per Kelas Pada Data Testing.....	17
Tabel 8. Jadwal Penelitian	21

DAFTAR LAMPIRAN

Lampiran 1. Perhitungan Kelas <i>Pothole</i>	25
Lampiran 2. Perhitungan Kelas <i>Alligator Crack</i>	25
Lampiran 3. Perhitungan Kelas <i>Linear Crack</i>	25
Lampiran 4. Tabel Laporan	26
Lampiran 5. Tabel Deteksi	26

BAB I

PENDAHULUAN

1.1 Latar Belakang

Kondisi infrastruktur jalan memiliki peran penting dalam mendukung mobilitas masyarakat dan aktivitas ekonomi (Agustin et al., 2025). Kerusakan jalan seperti lubang (*pothole*) dan retakan (*crack*) dapat menurunkan kenyamanan berkendara serta meningkatkan risiko kecelakaan lalu lintas (Aulia et al., 2024). Berdasarkan data Badan Pusat Statistik (BPS) tahun 2024, tercatat sebanyak 150.906 kasus kecelakaan lalu lintas di Indonesia dengan jumlah korban meninggal dunia mencapai 26.839 orang (Badan Pusat Statistik, 2025). Salah satu faktor yang berkontribusi terhadap kecelakaan tersebut adalah kondisi jalan yang rusak dan belum terpantau secara optimal.

Sistem pelaporan kerusakan jalan pada umumnya masih dilakukan secara konvensional dan belum terintegrasi secara optimal dengan sistem berbasis teknologi (Ardita et al., 2026). Proses pelaporan yang tidak terstruktur dapat menyebabkan keterlambatan dalam penanganan kerusakan serta kurangnya dokumentasi yang sistematis (Azza et al., 2025). Selain itu, keterbatasan media pelaporan juga menyebabkan masyarakat kesulitan dalam menyampaikan informasi dan monitoring terkait kondisi jalan secara langsung (Hartono et al., 2025). Oleh karena itu, diperlukan sistem pelaporan berbasis web yang mampu mengintegrasikan data kerusakan jalan secara terpusat dan mudah diakses oleh pengguna.

Perkembangan teknologi *deep learning*, khususnya dalam bidang *computer vision*, memungkinkan proses deteksi kerusakan jalan dilakukan secara otomatis menggunakan citra digital (Sasmito et al., 2023). Salah satu metode yang banyak digunakan adalah *You Only Look Once* YOLO yang mampu melakukan deteksi objek secara cepat dan akurat dalam satu proses (*single-pass*), sehingga metode ini sangat efektif diterapkan pada sistem deteksi *real-time* yang membutuhkan kecepatan pemrosesan tinggi tanpa mengurangi tingkat akurasi deteksi (Afriyanti, 2025). Beberapa penelitian sebelumnya telah memanfaatkan metode ini untuk mendeteksi kerusakan jalan seperti *pothole* dan *crack*, serta menunjukkan hasil yang lebih efisien dibandingkan metode inspeksi manual (Ranyal et al., 2022; Zhao et al., 2025).

Proses deteksi kerusakan jalan masih memiliki keterbatasan, terutama dalam membedakan jenis kerusakan yang memiliki karakteristik visual yang mirip serta belum terhubung dengan sistem pelaporan yang dapat digunakan secara langsung (Sofiani et al., 2025). Kondisi ini menyebabkan hasil deteksi belum dimanfaatkan secara optimal untuk mendukung proses monitoring kondisi jalan (Samsinar et al., 2024). Selain itu, keterbatasan integrasi antara proses deteksi otomatis dan sistem pelaporan berbasis web menyebabkan proses pemantauan kerusakan jalan belum berjalan secara efektif, sehingga diperlukan suatu sistem yang mampu menghubungkan proses identifikasi kerusakan dengan pelaporan kondisi jalan secara terintegrasi (Ismail & Rahmadewi, 2025).

Oleh karena itu, penelitian ini mengusulkan penerapan model YOLOv11 untuk mendeteksi kerusakan jalan secara otomatis berdasarkan citra digital, yang kemudian diintegrasikan ke dalam sistem pelaporan kerusakan jalan berbasis web. Hasil deteksi tersebut selanjutnya digunakan untuk mengidentifikasi jenis kerusakan seperti *pothole*, *linear crack*, dan *alligator crack*, serta dihitung menggunakan pendekatan *Road Damage Score* (RDS) untuk menentukan tingkat prioritas penanganan kerusakan jalan. Hasil akhir akan diimplementasikan dalam sistem monitoring berbasis *website* guna

memfasilitasi masyarakat dalam melaporkan kondisi jalan dan membantu pihak terkait dalam melakukan pemantauan serta penentuan prioritas perbaikan secara lebih efektif, terstruktur, dan tepat sasaran.

1.2 Tujuan Penelitian

Tujuan dari penelitian ini adalah menerapkan metode YOLOv11 untuk mendeteksi kerusakan jalan serta mengimplementasikannya pada sistem pelaporan berbasis web.

1.3 Ruang Lingkup Penelitian

Agar pembahasan masalah dalam penelitian ini lebih terfokus dan sesuai dengan tujuan yang ingin dicapai, maka diperlukan adanya batasan penelitian. Adapun batasan-batasan dalam penelitian ini adalah sebagai berikut:

1. Kategori kerusakan jalan yang dianalisis meliputi tiga kelas utama, yaitu *pothole*, *linear crack*, dan *alligator crack*.
2. *Dataset* yang digunakan pada penelitian kali ini terdiri dari data primer yang diambil langsung di kecamatan kemang dan data sekunder yang diambil dari *roboflow*.
3. Metode yang digunakan adalah YOLOv11 berbasis *deep learning* untuk mendeteksi objek kerusakan jalan.
4. Sistem dikembangkan dalam bentuk *website* sebagai media pelaporan dan visualisasi hasil deteksi.

1.4 Manfaat Penelitian

Penelitian yang dilakukan memiliki beberapa manfaat yang dapat dijelaskan sebagai berikut:

1. Menghasilkan model deteksi kerusakan jalan berbasis YOLOv11 yang dapat digunakan untuk mengidentifikasi jenis kerusakan jalan secara otomatis.
2. Menyediakan sistem pelaporan berbasis web yang dapat membantu dalam proses *monitoring* dan pelaporan kondisi kerusakan jalan secara lebih efektif.

BAB II LANDASAN TEORI

2.1 Tinjauan Pustaka

2.1.1 Kerusakan Kondisi Jalan

Kerusakan jalan merupakan kondisi menurunnya kualitas permukaan jalan yang dapat mengganggu kenyamanan serta keselamatan pengguna jalan (Lyona et al., 2025). Beberapa jenis kerusakan jalan yang umum ditemukan antara lain lubang (*pothole*), retak lurus (*linear crack*), dan retak kulit buaya (*alligator crack*), yang masing-masing memiliki karakteristik visual yang berbeda. *Pothole* berupa lubang pada permukaan jalan, *linear crack* berupa retakan memanjang, sedangkan *alligator crack* merupakan retakan bercabang menyerupai pola kulit buaya yang menunjukkan kerusakan jalan yang lebih serius (Cifuentes et al., 2024). Kerusakan jalan seperti lubang dan retakan merupakan salah satu permasalahan utama yang dapat menurunkan kualitas infrastruktur serta membahayakan pengguna jalan (Thakur et al., 2025). Dalam penelitian ini, kategori kerusakan mengacu pada jenis *pavement distress* yang umum ditemukan pada perkerasan jalan di Indonesia, yang secara umum juga digunakan dalam standar penilaian kondisi jalan oleh Kementerian Pekerjaan Umum dan Perumahan Rakyat (PUPR) bidang Bina Marga (Firmandari et al., 2025). Klasifikasi tersebut didasarkan pada karakteristik visual kerusakan permukaan jalan sehingga sesuai untuk digunakan dalam pendekatan berbasis citra digital.



Gambar 1. Kerusakan Jalan

2.1.2 Road Damage Score (RDS)

Road Damage Score (RDS) merupakan suatu pendekatan penilaian yang digunakan untuk menggambarkan tingkat kondisi kerusakan jalan dalam bentuk skor numerik berdasarkan tingkat kerusakan yang teridentifikasi (Ibragimov et al., 2024). Skor ini digunakan sebagai indikator sederhana untuk menunjukkan kualitas kondisi jalan, di mana nilai yang lebih tinggi menunjukkan kondisi jalan yang lebih baik, sedangkan nilai yang lebih rendah menunjukkan tingkat kerusakan yang lebih tinggi (Sunardi et al., 2025). Dalam penelitian ini, penilaian kondisi kerusakan jalan dilakukan menggunakan pendekatan sederhana berbasis pembobotan melalui *Road*

Damage Score (RDS), yaitu dengan memberikan nilai kondisi jalan berdasarkan jumlah objek kerusakan yang terdeteksi oleh model YOLOv11.

Metode ini merupakan adaptasi dari pedoman Dinas PU Bina marga yaitu konsep Indeks Kondisi Perkerasan (IKP) yang menyatakan kondisi jalan dalam bentuk skor berdasarkan tingkat kerusakan (Direktorat Jenderal Bina Marga, 2021). Pada metode IKP, penilaian dilakukan dengan mempertimbangkan luas area dan tingkat keparahan kerusakan, sedangkan dalam penelitian ini perhitungan disederhanakan hanya berdasarkan jumlah objek hasil deteksi (Saputra et al., 2025).

Penyederhanaan ini dilakukan karena model deteksi objek hanya menghasilkan informasi berupa jumlah objek dan *bounding box*, sehingga tidak memungkinkan perhitungan berbasis luas area secara akurat. Oleh karena itu, pendekatan yang digunakan bersifat *rule-based* dengan pemberian bobot pada setiap jenis kerusakan sebagai representasi tingkat dampak relatif terhadap keselamatan pengguna jalan (Joseph et al., 2024).

Dalam penelitian ini, *pothole* diberikan bobot tertinggi, diikuti *alligator crack*, dan *linear crack* sebagai kerusakan dengan dampak paling rendah. Dengan demikian, nilai RDS dihitung berdasarkan jumlah objek yang terdeteksi dikalikan dengan bobot masing-masing sebagai indikator tingkat keparahan relatif.

Rumus *Road Damage Score* (RDS) dinyatakan sebagai berikut:

$$RDS = 100 - (N_{pothole} \times 10 + N_{linear} \times 5 + N_{alligator} \times 7) \quad (1)$$

dengan:

$N_{pothole}$ = Jumlah *pothole* yang terdeteksi

N_{linear} = Jumlah *linear crack* yang terdeteksi

$N_{alligator}$ = Jumlah *alligator crack* yang terdeteksi

Nilai RDS berada pada rentang 0 hingga 100, di mana nilai mendekati 100 menunjukkan kondisi jalan yang baik, sedangkan nilai mendekati 0 menunjukkan kondisi jalan yang buruk. Untuk menjaga konsistensi, nilai RDS dibatasi minimum 0, sehingga hasil perhitungan yang bernilai negatif dikonversi menjadi 0 sebagai representasi kondisi terburuk.

Pendekatan pembobotan dalam penelitian ini juga mengacu pada prinsip penilaian pada metode *Pavement Condition Index* (PCI), di mana setiap jenis kerusakan memiliki tingkat pengaruh yang berbeda terhadap kondisi jalan. Oleh karena itu, setiap jenis kerusakan diberikan bobot yang berbeda sebagai representasi tingkat keparahan relatif. Penelitian sebelumnya menunjukkan bahwa kerusakan seperti *pothole* dan *alligator crack* memiliki dampak yang lebih signifikan terhadap keselamatan pengguna jalan dibandingkan jenis retakan lainnya (Jiang, 2024; Ranyal et al., 2022). Oleh karena itu, dalam penelitian ini digunakan pendekatan *rule-based* dengan pemberian bobot yang berbeda pada setiap jenis kerusakan sebagai bentuk adaptasi terhadap keterbatasan data berbasis citra.

Pendekatan ini tidak dimaksudkan untuk menggantikan metode standar seperti IKP atau PCI, melainkan digunakan sebagai indikator awal berbasis citra untuk mendukung proses monitoring kondisi jalan secara cepat dan praktis, penentuan bobot pada setiap jenis kerusakan dilakukan berdasarkan studi literatur serta pertimbangan tingkat dampak terhadap keselamatan pengguna jalan.

2.1.3 Pengolahan Citra Digital

Pengolahan citra digital merupakan tahapan penting dalam mempersiapkan data citra agar lebih sesuai digunakan dalam proses pelatihan maupun pengujian model (Mulyana & Wahyudi, 2025). Tahapan ini bertujuan untuk meningkatkan kualitas serta konsistensi data sehingga model dapat mengenali pola dengan lebih baik. *Preprocessing* yang umum dilakukan meliputi *resizing* untuk menyeragamkan ukuran citra, normalisasi untuk menyesuaikan nilai piksel, serta augmentasi data seperti rotasi dan perubahan pencahayaan untuk meningkatkan variasi citra. Dengan proses tersebut, model menjadi lebih stabil dan mampu bekerja dengan baik pada berbagai kondisi lingkungan (Budi et al., 2024).

2.1.4 Deep Learning

Deep learning merupakan metode pembelajaran mesin yang mampu mempelajari pola kompleks dari data citra tanpa perlu fitur manual (Munadi, 2025). Dalam kasus kerusakan jalan, *deep learning* banyak digunakan karena dapat meningkatkan kemampuan deteksi dan pengenalan pola kerusakan pada permukaan jalan dalam berbagai kondisi lingkungan (Sofiani et al., 2025). Jiang et al. (2024) menunjukkan bahwa pengembangan model deteksi berbasis *deep neural networks* dapat meningkatkan *precision*, *recall*, dan mAP pada kasus *road damage detection*.

2.1.5 Computer Vision

Computer vision merupakan bidang yang mempelajari cara komputer memahami informasi visual dari citra maupun video (Sutisna et al., 2024). Dalam implementasi monitoring jalan, *computer vision* digunakan untuk mengenali pola dan objek tertentu pada permukaan jalan sehingga proses inspeksi dapat dilakukan lebih cepat dan terstruktur (Zhan, 2024). Ruseruka et al. (2023) menjelaskan bahwa pemantauan kondisi jalan dapat dilakukan menggunakan kamera bawaan kendaraan sebagai sumber data visual, sehingga sistem *computer vision* dapat mendukung pemantauan jalan secara lebih efisien dan *real-time*.

2.1.6 Deteksi Objek

Deteksi objek merupakan proses dalam *computer vision* yang bertujuan untuk mengenali objek pada citra sekaligus menentukan lokasi objek tersebut menggunakan *bounding box* (Chen et al., 2025). Berbeda dengan klasifikasi citra, deteksi objek tidak hanya mengidentifikasi kategori objek, tetapi juga memberikan informasi posisi objek secara spesifik pada gambar. *Output* dari proses ini berupa label kategori, *confidence score*, serta koordinat *bounding box* yang dapat digunakan untuk analisis lebih lanjut.

2.1.7 Algoritma YOLO (*You Only Look Once*)

YOLO merupakan metode deteksi objek berbasis deep learning yang mampu melakukan deteksi secara *real-time* dengan pendekatan *single-stage detection* (Zhang et al., 2025). Algoritma YOLO membagi citra menjadi grid $S \times S$, di mana setiap sel bertanggung jawab mendeteksi objek yang pusatnya berada pada sel tersebut. Setiap *bounding box* direpresentasikan sebagaimana ditunjukkan pada Persamaan (2).

$$(x, y, w, h, C) \quad (2)$$

Transformasi koordinat *bounding box* dihitung sebagai berikut:

$$b_x = \sigma(t_x) + c_x \quad (3)$$

$$b_y = \sigma(t_y) + c_y \quad (4)$$

$$b_w = p_w e^{t_w} \quad (5)$$

$$b_h = p_h e^{t_h} \quad (6)$$

Keterangan:

1. t_x, t_y, t_w, t_h = *output* prediksi jaringan
2. c_x, c_y = koordinat *sel grid*
3. p_w, p_h = *anchor box*
4. σ = fungsi sigmoid

Nilai *Intersection over Union* (IoU) dinyatakan pada Persamaan (7). *Confidence score* pada Persamaan (8) dan skor akhir kelas pada Persamaan (9).

Nilai *Intersection over Union* (IoU) dihitung sebagai:

$$IoU = \frac{Area_{overlap}}{Area_{union}} \quad (7)$$

Confidence score dirumuskan sebagai:

$$Confidence = P(Object) \times IoU_{pred}^{truth} \quad (8)$$

Sehingga skor akhir kelas:

$$Score_i = P(Class_i|Object) \times Confidence \quad (9)$$

$$Confidence = P(Object) \times IoU_{pred}$$

Fungsi loss YOLO secara umum dinyatakan pada Persamaan (10).

Fungsi loss YOLO secara umum:


$$Loss = \lambda_{coord} \sum (error_{coord}) \quad (10)$$

$$+ \sum (error_{conf})$$

$$+ \sum (error_{class})$$

2.1.8 Arsitektur *You Only Look Once* (YOLOv11)

YOLOv11 merupakan generasi baru dari keluarga YOLO yang menawarkan peningkatan akurasi deteksi dengan arsitektur yang lebih ringan dan efisien dibandingkan versi sebelumnya (Zhao et al., 2025). YOLOv11 terdiri dari tiga komponen utama: *backbone* yang mengekstraksi fitur visual, *neck* yang menggabungkan fitur multi-skala, dan *detection head* yang menghasilkan prediksi *bounding box* beserta label kelas. Operasi konvolusi dinyatakan pada Persamaan (11) hingga Persamaan (15).



Gambar 2. Arsitektur YOLOv11

Gambar 2 menunjukkan arsitektur YOLOv11 yang terdiri atas tiga komponen utama, yaitu *backbone*, *neck*, dan *head*. Bagian *backbone* berfungsi mengekstraksi fitur visual dari citra masukan melalui serangkaian operasi konvolusi dan modul C3K2. Operasi konvolusi pada setiap *layer* digunakan untuk menangkap pola spasial seperti tepi, tekstur, dan bentuk kerusakan jalan. Secara matematis, operasi konvolusi pada *layer* ke- l dinyatakan pada Persamaan (11):

$$F_l = \sigma(W_l * F_{l-1} + b_l) \quad (11)$$

Pada persamaan tersebut F_l merupakan *feature map* pada *layer* ke- l , W_l adalah kernel konvolusi, F_{l-1} merupakan *feature map* dari *layer* sebelumnya, b_l adalah *bias*, dan σ merupakan fungsi aktivasi. Modul C3K2 pada bagian *backbone* menerapkan *shortcut connection* untuk menjaga kestabilan aliran gradien selama proses pelatihan. Mekanisme *residual connection* tersebut dirumuskan pada Persamaan (12):

$$y = F(x) + x \quad (12)$$

Nilai $F(x)$ menyatakan hasil transformasi konvolusi, sedangkan x merupakan *input* awal. Mekanisme ini membantu mengurangi permasalahan *vanishing gradient* selama pelatihan model. Bagian *neck* pada YOLOv11 menggunakan struktur *Feature Pyramid Network* (FPN) dan *Path Aggregation Network* (PANet) untuk menggabungkan fitur multi-skala melalui proses *upsampling* dan *concatenation*. Operasi penggabungan fitur dinyatakan pada Persamaan (13):

$$F_{concat} = [F_1; F_2] \quad (13)$$

Persamaan tersebut menunjukkan proses penggabungan dua *feature map* pada dimensi *channel*. YOLOv11 juga menggunakan modul *Spatial Pyramid Pooling Fast* (SPPF)

untuk memperluas *receptive field* melalui operasi *pooling* pada berbagai ukuran kernel. Operasi *max pooling* dinyatakan pada Persamaan (14):

$$F_{pool}(i, j) = \max_{(m, n) \in \Omega} F(i + m, j + n) \quad (14)$$

Simbol Ω menunjukkan area kernel *pooling*. Bagian *head* bertugas menghasilkan prediksi *bounding box*, *confidence score*, dan probabilitas kelas. Representasi *bounding box* dinyatakan pada Persamaan (15):

$$B = (x, y, w, h) \quad (15)$$

Parameter x dan y menunjukkan koordinat pusat *bounding box*, sedangkan w dan h menyatakan lebar serta tinggi kotak prediksi.

2.1.9 Evaluasi Model *You Only Look Once* (YOLO)

Evaluasi model dilakukan untuk mengukur kinerja YOLOv11 dalam mendeteksi objek kerusakan jalan berdasarkan citra (Takyudin et al., 2025). Pengukuran performa dilakukan menggunakan metrik evaluasi yang umum digunakan pada *object detection*, yaitu *Precision*, *Recall*, *F1-Score*, dan *Mean Average Precision* (mAP).

1. *Precision* digunakan untuk mengukur proporsi prediksi positif yang benar terhadap seluruh prediksi positif yang dihasilkan model. Nilai *Precision* dinyatakan pada Persamaan (16):

$$Precision = \frac{TP}{TP + FP} \quad (16)$$

Pada persamaan tersebut, TP menyatakan *true positive* dan FP menyatakan *false positive*. Nilai *Precision* yang tinggi menunjukkan bahwa sebagian besar hasil deteksi model merupakan prediksi yang benar. adalah *true positive*, dan FP adalah *false positive*, nilai *precision* yang tinggi menunjukan bahwa Sebagian besar deteksi model adalah benar.

2. *Recall* digunakan untuk mengukur kemampuan model dalam mendeteksi seluruh objek yang sebenarnya ada. Nilai *Recall* dinyatakan pada Persamaan (17):

$$Recall = \frac{TP}{TP + FN} \quad (17)$$

Nilai FN menyatakan *false negative*. Nilai *Recall* yang tinggi menunjukkan bahwa model mampu mendeteksi sebagian besar objek yang ada. adalah *false negative*, *recall* tinggi menunjukan model jarang melewatkan objek yang seharusnya terdeteksi.

3. *F1-Score* merupakan rata-rata harmonis antara *Precision* dan *Recall*, yang digunakan untuk menyeimbangkan kedua metrik tersebut dalam evaluasi model. Nilai *F1-Score* dinyatakan pada Persamaan (18):

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall} \quad (18)$$

Intersection over Union (IoU) digunakan untuk mengukur tingkat kesesuaian antara *bounding box* prediksi dan *ground truth*. Nilai IoU dinyatakan pada Persamaan (19):

$$IoU = \frac{Area_{overlap}}{Area_{union}} \quad (19)$$

Nilai IoU berada pada rentang 0 hingga 1, di mana nilai yang semakin mendekati 1 menunjukkan tingkat kecocokan yang semakin baik antara hasil prediksi dan data sebenarnya.

4. *Average Precision* (AP) dihitung berdasarkan luas area di bawah kurva *precision-recall*. Nilai AP dinyatakan pada Persamaan (20):

$$AP = \int_0^1 p(r) dr \quad (20)$$

Pada persamaan tersebut, $p(r)$ menyatakan nilai *precision* sebagai fungsi dari *recall*.

5. *Mean Average Precision* (mAP) merupakan rata-rata nilai AP dari seluruh kelas objek yang digunakan untuk mengevaluasi performa model secara keseluruhan. Nilai mAP dinyatakan pada Persamaan (21):

$$mAP = \frac{1}{N} \sum_{i=1}^N AP_i \quad (21)$$

Pada persamaan tersebut, N menyatakan jumlah kelas objek dan AP_i merupakan nilai *Average Precision* pada kelas ke- i .

2.1.10 Sistem Monitoring Berbasis *Website*

Sistem monitoring berbasis *website* adalah platform yang digunakan untuk menampilkan hasil pemantauan secara terstruktur agar mudah diakses oleh pengguna. Dalam penelitian ini, *website* berfungsi sebagai antarmuka pelaporan bagi masyarakat sekaligus visualisasi hasil deteksi dan penentuan prioritas kerusakan jalan. Urbiztondo et al. (2025) menunjukkan bahwa platform *monitoring* berbasis web dapat membantu proses pelaporan dan pengambilan keputusan kondisi jalan secara lebih efisien. Sistem dikembangkan menggunakan Supabase sebagai platform *backend* berbasis *cloud* dengan basis data PostgreSQL, serta Sistem dikembangkan menggunakan *backend* berbasis *cloud* dan *database* relasional.

2.2 Penelitian Terdahulu

Penelitian terdahulu dilakukan untuk tujuan membandingkan, mendapatkan referensi, serta menemukan gagasan baru yang bisa dijadikan dasar bagi penelitian selanjutnya. Berikut ini beberapa penelitian terdahulu yang masih relevan dengan topik yang sedang diteliti oleh penulis:

1. Nama : Shizheng Zhang, Zhihao Liu,
Kunpeng Wang, Wanwei Huang, Pu Li
Judul : OBC-YOLOv8: an improved road damage detection model based
on YOLOv8
Tahun : (2025)

- Isi Penelitian : Penelitian ini mengembangkan model YOLOv8 yang dimodifikasi untuk meningkatkan performa deteksi kerusakan jalan. Fokus utama pada peningkatan akurasi model tanpa membahas implementasi sistem pelaporan.
2. Nama : Eshta Ranyal, Ayan Sadhu, Kamal Jain
 Judul : *Road Condition Monitoring Using Smart Sensing and Artificial Intelligence*
 Tahun : (2022)
 Isi Penelitian : Penelitian ini merupakan studi literatur yang membahas berbagai metode berbasis AI untuk monitoring kondisi jalan. Digunakan sebagai dasar teori bahwa *deep learning* efektif dalam deteksi kerusakan jalan.
 3. Nama : Miao Ren, Xianfeng Zhang, Xiao Chen, Bo Zhou, Ziyuan Feng
 Judul : *YOLOv5s-M: A Deep Learning Network Model for Road Pavement Damage Detection from Urban Street-View Imagery*
 Tahun : (2023)R(Thakur et al., 2025)
 Isi Penelitian : Penelitian ini mengusulkan model YOLOv5s-M untuk deteksi kerusakan perkerasan jalan perkotaan menggunakan citra *street-view*. Model dikembangkan melalui penambahan lapisan deteksi skala besar, penggunaan *Generalized-FPN* pada bagian *neck* untuk fusi fitur lintas lapisan dan skala, serta penerapan Decoupled Head dan fungsi *loss* LIoU. *Dataset* terdiri dari 156.304 citra *street-view* dari Distrik Fengtai, Beijing yang mencakup tujuh kategori kerusakan. Hasil evaluasi menunjukkan *precision* sebesar 0,782 dan mAP0.5 sebesar 79,8%. Penelitian ini mendemonstrasikan kelayakan deteksi kerusakan jalan skala besar menggunakan citra kamera kendaraan sebagai sumber data utama.
 4. Nama : Wenjin Chen, Jia Sheng Yang, Chenbo Xia, Yaosong Li, Xu Xiao
 Judul : *Road Surface Damage Detection Based on Enhanced YOLOv8*
 Tahun : (2025)
 Isi Penelitian : Penelitian ini mengusulkan peningkatan arsitektur YOLOv8 untuk deteksi kerusakan jalan dengan mengoptimalkan *backbone*, *neck*, dan parameter pelatihan. Hasilnya menunjukkan peningkatan performa deteksi, khususnya pada *precision* dan mAP, tanpa menambah kompleksitas komputasi secara signifikan.
 5. Nama : Michael Urbiztondo, Mingjian Wu, Tae J. Kwon
 Judul : *Advancing Winter Road Maintenance: An AI-driven Web Platform for Real-time Road Condition Monitoring and Spatial Analysis*
 Tahun : (2025)
 Isi Penelitian : Penelitian ini mengembangkan platform berbasis web berbasis AI untuk pemantauan kondisi jalan secara *real-time* dengan integrasi data visual dan lokasi. Sistem ini meningkatkan efektivitas

monitoring serta mendukung pengambilan keputusan melalui visualisasi data yang terstruktur.

2.3 Perbandingan Terdahulu


Berdasarkan hasil analisis penelitian terdahulu, sebagian besar studi berfokus pada peningkatan akurasi deteksi kerusakan jalan menggunakan metode *deep learning*, khususnya algoritma YOLO, tanpa mengintegrasikan hasil deteksi ke dalam sistem pelaporan yang dapat digunakan secara langsung oleh pengguna. Selain itu, mekanisme penentuan prioritas penanganan kerusakan jalan berdasarkan hasil deteksi juga belum banyak dibahas. Oleh karena itu, penelitian ini menghadirkan pendekatan yang mengintegrasikan deteksi kerusakan jalan menggunakan YOLOv11 dengan sistem pelaporan berbasis web serta penilaian kondisi jalan menggunakan *Road Damage Score* (RDS) untuk mendukung proses monitoring dan pengambilan keputusan secara lebih efektif.

Tabel 1. Perbandingan Terdahulu

No	Nama Peneliti, Tahun	Metode		Teknologi			
		a	b	c	d	e	f
1	Zhang et al., 2025	✓	✓	✓	✓		
2	Ranyal et al., 2022	✓					
3	Ren et al., 2023	✓	✓				
4	Chen et al., 2025	✓	✓	✓	✓		
5	Urbiztondo et al, 2025	✓				✓	
6	Arya Maulana, 2026 (Penelitian ini)	✓	✓	✓		✓	✓

A = Deep Learning; B = Object Detection; C =YOLO / YOLO-Based; D= Modifikasi Arsitektur; E = System website; F = Penentuan Prioritas (RDS)

Tabel 2. Diagram SLR




BAB III

METODE PENELITIAN

3.1 Metode Penelitian

Metode penelitian dirancang secara sistematis seperti yang ditunjukkan pada Gambar 5, yang menggambarkan alur penelitian mulai dari tahap perencanaan hingga tahap implementasi sistem. Penelitian ini bertujuan untuk mengembangkan sistem deteksi kerusakan jalan berbasis *deep learning* dengan memanfaatkan model YOLOv11 untuk mendeteksi jenis kerusakan jalan pada citra.

Hasil deteksi tersebut kemudian digunakan untuk mengidentifikasi jenis serta jumlah kerusakan jalan yang selanjutnya diolah menggunakan pendekatan *rule-based* berupa *Road Damage Score* (RDS) sebagai indikator tingkat kerusakan jalan. Nilai tersebut digunakan sebagai dasar dalam menentukan prioritas penanganan kerusakan jalan. Seluruh tahapan penelitian dilakukan secara terstruktur mulai dari proses perencanaan, pengumpulan dan pengolahan *dataset*, pelatihan model YOLOv11, evaluasi performa model, hingga implementasi sistem pelaporan berbasis *website*.



Gambar 3. Alur Penelitian

3.1.1 Perencanaan

Tahap perencanaan merupakan tahap awal dalam penelitian yang bertujuan untuk menentukan ruang lingkup penelitian, tujuan penelitian, serta metode yang akan digunakan dalam pengembangan sistem deteksi kerusakan jalan. Pada tahap ini dilakukan identifikasi permasalahan yang berkaitan dengan kondisi jalan yang rusak serta kebutuhan sistem pelaporan yang mampu mendeteksi kerusakan jalan secara otomatis menggunakan teknologi pengolahan citra dan *deep learning*.

Selain itu, pada tahap ini juga ditetapkan penggunaan model YOLOv11 untuk mendeteksi objek kerusakan jalan. Hasil deteksi kemudian akan diolah menggunakan pendekatan *rule-based* berupa *Road Damage Score* (RDS) sebagai indikator tingkat kerusakan jalan, serta diimplementasikan dalam sistem pelaporan berbasis *website* yang dapat digunakan oleh masyarakat dan pihak kecamatan.

3.1.2 Studi literatur

Tahap studi literatur dilakukan dengan mengkaji berbagai referensi ilmiah yang berkaitan dengan penelitian yang dilakukan. Referensi yang digunakan meliputi jurnal ilmiah, buku, serta publikasi penelitian yang membahas mengenai *computer vision*, *deep learning*, metode *object detection*, serta arsitektur YOLO sebagai dasar dalam proses deteksi kerusakan jalan. Selain itu, studi literatur juga mencakup penelitian terkait sistem monitoring berbasis *website* untuk memahami konsep implementasi sistem pelaporan yang dapat digunakan oleh pengguna secara langsung.

Selain itu, dilakukan kajian terhadap metode penilaian kondisi jalan seperti *Pavement Condition Index* (PCI) sebagai dasar konseptual dalam memahami perbedaan tingkat kerusakan jalan. Konsep tersebut kemudian diadaptasi dalam penelitian ini menjadi pendekatan sederhana berbasis *rule-based* melalui metode *Road Damage Score* (RDS), yang disesuaikan dengan karakteristik data hasil deteksi objek berbasis citra.

3.1.3 Metode *Knowledge Discovery in Database* (KDD)

Proses pengolahan data dalam penelitian ini menggunakan pendekatan *Knowledge Discovery in Database* (KDD). Metode KDD merupakan proses yang digunakan untuk mengekstraksi pengetahuan atau informasi dari kumpulan data melalui beberapa tahapan yang terstruktur. Tahapan dalam metode KDD meliputi data *understanding*, data *selection*, data *preprocessing*, data *transformation*, data *mining*, serta data *interpretation/evaluation*. Melalui tahapan tersebut, data yang awalnya berupa kumpulan citra kerusakan jalan diolah secara sistematis sehingga dapat menghasilkan informasi yang berguna dalam proses deteksi dan analisis kondisi jalan.

3.1.3.1 Data Understanding

Tahap *Data Understanding* (Deskripsi Data) merupakan tahap awal dalam metode KDD yang bertujuan untuk memahami karakteristik *dataset* yang digunakan dalam penelitian. Pada tahap ini dilakukan identifikasi jumlah data, distribusi kelas, serta kualitas citra yang digunakan sebagai *input* model.

Dataset yang digunakan terdiri dari tiga kategori kerusakan jalan, yaitu *pothole*, *linear crack*, dan *alligator crack*. Selain itu, dilakukan analisis distribusi anotasi untuk mengetahui adanya ketidakseimbangan kelas (*class imbalance*) yang dapat mempengaruhi performa model. Hasil dari tahap ini digunakan sebagai dasar dalam menentukan strategi *preprocessing* dan augmentasi data pada tahap selanjutnya.

3.1.3.2 Data Selection

Tahap *Data Selection* merupakan proses pemilihan dan pengumpulan data yang digunakan sebagai bahan utama dalam penelitian. Data yang digunakan berupa citra kerusakan jalan yang terdiri dari tiga kategori, yaitu *pothole*, *linear crack*, dan *alligator crack*, yang telah melalui proses anotasi untuk mendukung pelatihan model deteksi objek menggunakan YOLOv11.

Data diperoleh dari dua sumber, yaitu data primer yang diambil langsung oleh peneliti menggunakan kamera *smartphone* dengan resolusi 4069×3072 piksel di ruas jalan Kabupaten Bogor, Jawa Barat, serta data tambahan dari *dataset* yang telah tersedia. Total *dataset* yang digunakan berjumlah 3.308 citra dengan 6.386 anotasi objek. Distribusi data menunjukkan adanya ketidakseimbangan kelas (*class*


imbalance), di mana kelas *pothole* memiliki jumlah anotasi paling banyak, sedangkan *alligator crack* paling sedikit.

Keterbatasan jumlah data dan ketidakseimbangan distribusi kelas diatasi melalui penerapan teknik augmentasi untuk meningkatkan kemampuan generalisasi model. Distribusi jumlah anotasi untuk setiap kelas kerusakan jalan disajikan pada Tabel 3.

Tabel 3. Distribusi Anotasi *Dataset* per Kelas

No	Kelas Kerusakan	Jumlah Anotasi	Persentase (%)
1	<i>Pothole</i>	2.709	42,42
2	<i>Linear Crack</i>	2.039	31,93
3	<i>Alligator Crack</i>	1.638	25,65
Total		6.386	100%

Berdasarkan Tabel 3, kelas *pothole* memiliki jumlah anotasi terbanyak yaitu 2.709 data atau sebesar 42,42%, diikuti oleh *linear crack* sebanyak 2.039 data dan *alligator crack* sebanyak 1.638 data. Perbedaan jumlah anotasi antar kelas menunjukkan adanya ketidakseimbangan distribusi data yang perlu diperhatikan dalam proses pelatihan model agar performa deteksi pada setiap kelas tetap optimal. Contoh hasil anotasi citra kerusakan jalan yang digunakan dalam proses pelatihan model ditunjukkan pada Gambar 4.



Gambar 4. *Dataset* Kerusakan Jalan

Gambar 4 menunjukkan contoh hasil anotasi pada *dataset* kerusakan jalan, di mana setiap objek kerusakan telah diberi *bounding box* sesuai dengan kelasnya masing-masing. Proses anotasi ini dilakukan untuk memberikan label pada objek sehingga model YOLOv11 dapat mempelajari karakteristik visual dari setiap jenis kerusakan jalan pada tahap pelatihan.

3.1.3.3 Data Preprocessing

Tahap Data *Preprocessing* dilakukan untuk menyeragamkan kualitas dan format citra sebelum pelatihan model YOLOv11. Proses ini bertujuan menjaga konsistensi karakteristik data agar pelatihan stabil dan performa model optimal. Pada

penelitian ini, parameter *preprocessing* dan augmentasi utama mengikuti konfigurasi *training* model aktif.

3.1.3.4 Data Transformation

Pada tahap ini dilakukan proses transformasi data citra melalui teknik augmentasi untuk memperkaya variasi *dataset* sebelum digunakan dalam pelatihan model YOLOv11. Transformasi ini bertujuan untuk mensimulasikan berbagai kondisi nyata saat pengambilan gambar, seperti perubahan orientasi, posisi objek, skala objek, serta variasi pencahayaan. Dengan transformasi tersebut, model diharapkan memiliki kemampuan generalisasi yang lebih baik dan mampu bekerja dengan baik pada berbagai kondisi lingkungan.

Selain augmentasi, citra juga direpresentasikan ke bentuk numerik agar dapat diproses oleh model *deep learning*. Setiap citra diproses pada ukuran *input* 640×640 piksel dan direpresentasikan dalam format RGB. Adapun jenis transformasi yang digunakan pada penelitian ini ditunjukkan pada Tabel 4.

Pemilihan jenis dan parameter augmentasi disesuaikan dengan kebutuhan untuk meningkatkan variasi data, terutama dalam menghadapi perbedaan kondisi pencahayaan, sudut pengambilan gambar, serta variasi posisi objek pada citra.

Tabel 4. Tranformasi data

No	Jenis Transformasi	Nilai/Parameter
1	Horizontal Flip	50%
2	<i>Mosaic</i>	100%
3	<i>Mixup</i>	10%
4	<i>Translate</i>	$\pm 10\%$
5	<i>Scale</i>	$\pm 50\%$
6	Penyesuaian Hue	$\pm 1,5\%$
7	Penyesuaian <i>Saturation</i>	$\pm 70\%$
8	Penyesuaian <i>Brightness (Value)</i>	$\pm 40\%$
9	<i>RandAugment</i>	Aktif
10	<i>Random Erasing</i>	40%

3.1.3.5 Data Mining


Tahap Data Mining merupakan proses penerapan model YOLOv11 untuk mengekstraksi informasi dari data citra kerusakan jalan yang telah melalui tahapan *Data Selection*, *Data Preprocessing*, dan *Data Transformation*. Pada fase ini, model digunakan untuk mendeteksi serta mengklasifikasikan tiga jenis kerusakan jalan, yaitu *alligator crack*, *linear crack*, dan *pothole*. Proses utama pada tahap ini meliputi:

1. Proses pelatihan dilakukan menggunakan *training set* sebanyak 2.736 citra untuk mempelajari fitur visual dari masing-masing kelas kerusakan berdasarkan anotasi *bounding box*. Pelatihan dilakukan selama 200 *epoch* dengan mekanisme *early stopping* menggunakan nilai *patience* sebesar 40.
2. Proses validasi dilakukan pada setiap epoch menggunakan *validation set* sebanyak 286 citra untuk memantau performa model serta mencegah terjadinya *overfitting*.
3. Pengujian akhir dilakukan menggunakan *test set* sebanyak 286 citra untuk mengevaluasi kemampuan generalisasi model terhadap data yang belum pernah dilihat sebelumnya.

Output model berupa prediksi *bounding box*, label kelas, dan *confidence score* untuk setiap objek yang terdeteksi. Hasil deteksi ini selanjutnya digunakan sebagai *input* dalam perhitungan *Road Damage Score* (RDS) serta penentuan prioritas perbaikan berbasis aturan.

Gambaran arsitektur YOLOv11 dalam proses deteksi objek dapat dilihat pada Gambar 5, Spesifikasi dan komponen arsitektur model YOLOv11 yang digunakan dalam penelitian ini ditampilkan pada Tabel 5 dan Tabel 6 sebagai acuan konfigurasi pelatihan dan kompleksitas model.

GAMBARAN PROSES MATRIKS PADA ARSITEKTUR YOLOV11



Gambar 5. Arsitektur YOLOv11 untuk Deteksi Objek

Tabel 5. Spesifikasi Model YOLOv11.


Parameter	Nilai
Arsitektur Model	YOLOv11n
Total Layer	181
Total Parameter	2.624.080
Kompleksitas Komputasi	6,6 GFLOPs
Input Size	640 × 640 piksel
Jumlah Kelas	3 (<i>alligator crack</i> , <i>linear crack</i> , <i>pothole</i>)
Epoch	200
Patience	40
Batch Size	8
Optimizer	AdamW

Tabel 6. Komponen Arsitektur YOLOv11

Komponen	Modul Utama	Fungsi
<i>Backbone</i>	Conv, C3k2, SPPF, C2PSA	Mengekstraksi fitur visual multi-skala dari citra <i>input</i>
<i>Neck</i>	Upsample, Concat, C3k2	Menggabungkan dan memperkuat fitur dari berbagai resolusi
<i>Head</i>	Detect	Menghasilkan prediksi bounding box dan klasifikasi objek

3.1.3.6 Data Evaluation

Tahap akhir metode *Knowledge Discovery in Database* (KDD) adalah *Data Evaluation*, yaitu proses menganalisis dan menafsirkan hasil tahap data mining. Pada penelitian ini, evaluasi kinerja model YOLOv11 dilakukan pada data *testing* sebanyak 286 citra dengan 562 *instance* anotasi, untuk mengukur kemampuan model dalam mendeteksi tiga kelas kerusakan jalan: *alligator crack*, *linear crack*, dan *pothole*. Visualisasi *confusion matrix* ditampilkan pada gambar hasil evaluasi model.



Gambar 6. Visualisasi *Confusion Matrix* Model YOLOv11

Berdasarkan *confusion matrix* tersebut, model YOLOv11 menunjukkan performa terbaik pada kelas *pothole* (215 prediksi benar), disusul *linear crack* (105) dan *alligator crack* (77), sehingga kemampuan deteksi objek utama sudah terlihat. Namun, kesalahan masih cukup dominan pada interaksi dengan *background*, terdapat prediksi objek pada *background* (*alligator* 40, *linear* 91, *pothole* 77) dan objek yang tidak terdeteksi lalu masuk *background* (*alligator* 51, *linear* 68, *pothole* 53).

Hasil evaluasi menunjukkan bahwa model masih memiliki keterbatasan dalam membedakan objek kerusakan dengan latar belakang yang memiliki karakteristik visual serupa, serta pada kelas dengan jumlah data yang relatif lebih sedikit. Hal ini menunjukkan adanya potensi kesalahan deteksi (*false positive* dan *false negative*) yang masih perlu ditingkatkan.

Tabel 7. Hasil evaluasi YOLOv11 per Kelas Pada Data Testing

Kelas	<i>Images</i>	<i>Instances</i>	<i>Precision</i>	<i>Recall</i>	mAP50	F1 Score
All (rata-rata)	286	562	0,6753	0,6169	0,6374	0,6448
<i>Alligator Crack</i>	286	110	0,6539	0,5668	0,5766	0,6072
<i>Linear Crack</i>	286	206	0,6010	0,5046	0,5031	0,5486
<i>Pothole</i>	286	246	0,7708	0,7795	0,8323	0,7751

Berdasarkan Tabel 7, kelas *pothole* memiliki performa tertinggi dengan mAP50 sebesar 0,8323, sedangkan kelas *linear crack* menunjukkan performa terendah dengan mAP50 sebesar 0,5031. Perbedaan ini menunjukkan bahwa karakteristik retakan linear relatif lebih menantang untuk dilokalisasi secara presisi dibandingkan *pothole*. Perhitungan F1-Score keseluruhan berdasarkan nilai *precision* dan *recall* rata-rata model adalah sebagai berikut:

Rumus *Precision* bisa dilihat pada persamaan 16

$$Precision_{overall} = 0,6753$$

Rumus *Recall* bisa dilihat pada persamaan 17

$$Recall_{overall} = 0,6169$$

Rumus F1-score bisa dilihat pada persamaan 18

$$F1-Score_{overall} = \frac{2 \times 0,6753 \times 0,6169}{0,6753 + 0,6169} = 0,6448 = 64,48\%$$

Adapun hasil perhitungan individual pada setiap kelas disajikan secara lengkap pada Lampiran 1 sampai 3.

3.1.4 Tahap Analisis Sistem

Tahap analisis sistem bertujuan untuk merumuskan kebutuhan sistem pelaporan kerusakan jalan berbasis website yang memanfaatkan model YOLOv11 sebagai detektor objek. Sistem menerima *input* berupa citra atau video, kemudian melakukan deteksi jenis kerusakan jalan secara otomatis serta mengolah hasil deteksi menjadi informasi kondisi jalan menggunakan pendekatan *Road Damage Score* (RDS) berbasis aturan. Tahap ini mencakup identifikasi alur kerja sistem, kebutuhan data, serta spesifikasi fungsional dan non-fungsional sebagai dasar perancangan sistem.

Sistem dikembangkan dalam ruang lingkup wilayah Kecamatan Kemang, Kabupaten Bogor, dengan pengguna terdiri dari masyarakat sebagai pelapor dan pihak kecamatan sebagai pengelola laporan. Pemanfaatan layanan berbasis lokasi dilakukan melalui *Global Positioning System* (GPS) untuk memperoleh koordinat latitude dan longitude secara *real-time* saat pelaporan.

Akses lokasi menjadi syarat wajib dalam penggunaan sistem, sehingga sistem tidak dapat digunakan apabila izin lokasi tidak diberikan. Selain itu, pengguna diwajibkan memasukkan alamat email sebagai sarana umpan balik terhadap tindak lanjut laporan.

Visualisasi lokasi kerusakan jalan ditampilkan melalui peta digital berbasis Leaflet dengan dukungan API wilayah.id untuk memperoleh informasi administratif secara otomatis. Nilai RDS yang dihasilkan selanjutnya digunakan sebagai dasar penentuan prioritas penanganan kerusakan jalan menggunakan pendekatan *rule-based*.

3.1.5 Tahap Desain Sistem

Tahap desain sistem dilakukan berdasarkan hasil analisis kebutuhan yang telah dirumuskan sebelumnya. Pada tahap ini dilakukan perancangan arsitektur sistem, alur kerja sistem, rancangan basis data, serta desain antarmuka pengguna pada *website* pelaporan kerusakan jalan.

Desain sistem difokuskan pada integrasi antara proses *input* data oleh pengguna, deteksi kerusakan menggunakan model YOLOv11, serta penyajian hasil deteksi dalam bentuk visualisasi dan informasi kondisi jalan berbasis web.

Pada tahap desain, sistem juga dirancang menggunakan peta digital berbasis Leaflet untuk menampilkan lokasi kerusakan jalan secara visual. Integrasi data wilayah dilakukan menggunakan *Application Programming Interface* (API) dari wilayah.id untuk memperoleh informasi administratif lokasi secara otomatis, selain itu, sistem mengimplementasikan mekanisme penentuan prioritas penanganan berbasis *rule-based* yang dihitung dari nilai *Road Damage Score* (RDS), sehingga setiap laporan dapat diklasifikasikan berdasarkan tingkat urgensi perbaikan.

3.1.5.1 Perancangan Basis Data

Perancangan basis data dilakukan untuk mendukung proses penyimpanan, pengelolaan, serta pengambilan data pada sistem pelaporan kerusakan jalan. Basis data dirancang menggunakan pendekatan relasional dengan memanfaatkan PostgreSQL yang dikelola melalui platform Supabase.

Pengelolaan skema dan akses data dilakukan menggunakan Drizzle ORM sebagai lapisan abstraksi, sehingga memudahkan dalam pengelolaan struktur tabel, relasi antar data, serta proses *query* secara terstruktur dan efisien. Basis data ini menyimpan informasi laporan pengguna, hasil deteksi kerusakan, nilai *Road Damage Score* (RDS), serta koordinat lokasi berbasis *Global Positioning System* (GPS).


Struktur basis data dirancang untuk merepresentasikan entitas utama dalam sistem, yaitu data laporan sebagai *input* pengguna serta data hasil deteksi sebagai *output* dari model YOLOv11. Relasi antar tabel digunakan untuk menghubungkan setiap laporan dengan hasil deteksi yang dihasilkan secara terstruktur, sehingga mendukung proses penyimpanan dan pengolahan data secara konsisten.

Rincian lengkap struktur tabel basis data yang digunakan dalam penelitian ini disajikan pada Lampiran 4 dan 5.

3.1.5.2 Flowchart Program

Flowchart sistem menggambarkan alur operasional sistem pelaporan kerusakan jalan berbasis *website*, mulai dari proses *input* oleh pengguna hingga penyajian hasil. Proses diawali dengan pengguna yang mengunggah citra atau video, kemudian sistem melakukan validasi data sebelum diproses menggunakan model YOLOv11 untuk mendeteksi objek kerusakan jalan.

Apabila kerusakan terdeteksi, sistem menghitung nilai *Road Damage Score* (RDS) sebagai indikator kondisi jalan, sedangkan jika tidak ditemukan kerusakan, sistem langsung menampilkan informasi kondisi jalan baik. Hasil deteksi dan nilai RDS selanjutnya disimpan ke dalam basis data dan ditampilkan pada *dashboard* monitoring. Representasi detail *flowchart* disajikan pada Gambar 7.



Gambar 7. Flowchart Sistem

3.1.6 Tahap Implementasi

Tahap implementasi merupakan proses realisasi sistem yang telah dirancang menjadi aplikasi berbasis web. Sistem dikembangkan menggunakan Python sebagai *backend* untuk menjalankan model YOLOv11 dalam proses deteksi kerusakan jalan.

Basis data menggunakan PostgreSQL yang dikelola melalui Supabase sebagai *backend-as-a-service*, serta Drizzle ORM untuk pengelolaan skema dan akses data. Implementasi sistem mencakup pengembangan fitur unggah data oleh pengguna, proses deteksi otomatis, perhitungan nilai RDS, serta penyimpanan dan visualisasi hasil deteksi dalam *dashboard* monitoring berbasis web.

BAB IV TATA LAKSANA PENELITIAN

4.1 Waktu dan Tempat Penelitian

4.1.1 Waktu Penelitian

Penelitian ini dilaksanakan dalam kurun waktu tiga bulan, yaitu sejak Maret 2026 hingga Mei 2026. Rentang waktu tersebut digunakan untuk seluruh rangkaian kegiatan penelitian.

4.1.2 Tempat Penelitian

Penelitian ini dilaksanakan di Kecamatan Kemang, Kabupaten Bogor, Provinsi Jawa Barat. Kecamatan Kemang dipilih sebagai lokasi penelitian karena memiliki karakteristik wilayah yang relevan dengan fokus penelitian.

4.2 Jadwal Penelitian

Rencana kegiatan penelitian yang dilaksanakan ditunjukkan pada Tabel 8.

Tabel 8. Jadwal Penelitian

No	Kegiatan	Bulan											
		Bulan 1				Bulan 2				Bulan 3			
		1	2	3	4	1	2	3	4	1	2	3	4
1	Pengumpulan Data												
2	Data <i>Preprocessing</i>												
3	Training & Pengujian YOLOv11												
4	Implementasi ke <i>Website Monitoring</i>												
5	Evaluasi Sistem												
6	Pembuatan Laporan												

4.3 Alat dan Bahan Penelitian

4.3.1 Alat Penelitian

Alat dan bahan penelitian ini meliputi perangkat lunak dan perangkat keras.

1. Perangkat lunak (*Software*): Visual Studio, Google Colab, Google Chrome, dan Microsoft 365.
2. Perangkat Keras (*Hardware*): Laptop Axio PONGO 725 dengan *prosesor* Intel Core i7-12650H, GPU NVIDIA *GeForce* RTX 2050, RAM 16 GB, dan penyimpanan 512 GB SSD.

4.3.2 Bahan Penelitian

Bahan penelitian yang digunakan yaitu:

1. *Dataset* Foto Jalan rusak
2. *Library* dan *Framework* yang digunakan dalam penelitian ini meliputi Python, Ultralytics YOLO (YOLOv11), PyTorch, OpenCV, NumPy, React, Leaflet, Supabase.
3. Buku, jurnal, dan skripsi sebagai bahan referensi pembuatan laporan penelitian.
4. Buku panduan penulisan skripsi dan tugas akhir Ilmu Komputer, FMIPA UNPAK.

DAFTAR PUSTAKA

- Afriyanti, L. (2025). Kombinasi Teknik Pemrosesan Citra untuk Peningkatan Pendeteksian Objek Pada Carla Simulator Combination of Image Processing Techniques to Improve Accuracy of Object Detection in CARLA Simulator. *JIKO (Jurnal Informatika dan Komputer)*, 9(3), 524–538. <https://doi.org/10.26798/jiko.v9i3.1958>
- Agustin, N., Mulyadi, A., & Amirulloh, M. R. (2025). Peran Dinas Pekerjaan Umum dalam Pemeliharaan dan Perbaikan Infrastruktur Jalan di Ruas Jalan Pangleseran-Cibatu Kabupaten Sukabumi. *Journal Of Social Science Research*, 5(1), 6606–6617. <https://doi.org/10.31004/innovative.v5i1.17922>
- Ardita, S. P., Al-Ikhsan, S. H., & Wulandari, B. (2026). Pengembangan Sistem Monitoring dan Evaluasi Kecelakaan Lalu Lintas Berbasis Website Untuk Mendukung Pengambilan Keputusan di Kota Bogor. *Jurnal Mahasiswa Teknik Informatika*, 10(2), 2423–2428. <https://doi.org/10.36040/jati.v10i2.17429>
- Aulia, S., Anisa, S. N., Indah, A., Dipa, M. A. K., & Panorama, M. (2024). Analisis Peran Infrastruktur Dalam Pertumbuhan Ekonomi Pembangunan Di Kota Palembang. *Jurnal Publikasi Ekonomi dan Akuntansi (JUPEA)*, 4(1), 36–54. <https://doi.org/10.51903/jupea.v4i1.2435>
- Azza, Z., Aprianto, R., & Ayu, P. (2025). Sistem Informasi Pelaporan Kerusakan Infrastruktur Jalan Berbasis Website. *Jurnal Sistem Informasi TGD*, 4(September), 1130–1139. <https://doi.org/10.53513/jursi.v4i5.11764>
- Badan Pusat Statistik. (2025, Desember 8). *Jumlah Kecelakaan, Korban Mati, Luka Berat, Luka Ringan, dan Kerugian Materi, 2024*. Badan Pusat Statistik. <https://www.bps.go.id/id/statistics-table/2/NTEzIzI=/jumlah-kecelakaan--korban-mati--luka-berat--luka-ringan--dan-kerugian-materi.html>
- Budi, E. S., Chan, A. N., Alda, P. P., & Idris, M. A. F. (2024). Optimasi Model Machine Learning untuk Klasifikasi dan Prediksi Citra Menggunakan Algoritma Convolutional Neural Network. *Rekayasa Teknik Informatika dan Informasi*, 4(5), 502–509.
- Chen, W., Yang, J. S., Xia, C., Li, Y., & Xiao, X. (2025). Road surface damage detection based on enhanced YOLOv8. *Computers in Industry*, 173, 104363. <https://doi.org/10.1016/j.compind.2025.104363>
- Cifuentes, L. T., Marulanda, J., & Thomson, P. (2024). Detection and classification of pavement damages using wavelet scattering transform, fractal dimension by box-counting method and machine learning algorithms. *Road Materials and Pavement Design*, 25(3), 566–584. <https://doi.org/10.1080/14680629.2023.2219338>
- Direktorat Jenderal Bina Marga. (2021). *Pedoman Penentuan Indeks Kondisi Perkerasan (IKP)*. Direktorat Jenderal Bina Marga. <https://binamarga.pu.go.id/index.php/nspk/detail/pedoman-penentuan-indeks-kondisi-perkerasan-ikp>
- Firmandari, U. R., Mukti, E. T., & Mayuni, S. (2025). Damage Condition Analysis Of Semparuk – Bentunai Road With Surface Distress Index (SDI) And Bina Marga Method. *Jurnal Teknik Sipil*, 25(3), 2310–2321. <https://doi.org/10.26418/jts.v25i3.90439>
- Hartono, A. H., Pratiwi, D. A., Arifin, S., Fatoni, M., & Endayani. (2025). Implementasi Program Pembangunan Infrastruktur Ruas Jalan Dinas PUPR

- Kabupaten Lebak. *Jurnal Syntax Imperatif: Jurnal Ilmu Sosial dan Pendidikan*, 6(3), 794–805. <https://doi.org/10.54543/syntaximperatif.v6i3.760>
- Ibragimov, E., Kim, Y., Lee, J. H., Cho, J., & Lee, J.-J. (2024). Automated Pavement Condition Index Assessment with Deep Learning and Image Analysis: An End-to-End Approach. *Sensors*, 24(7), 2333. <https://doi.org/10.3390/s24072333>
- Ismail, D. R., & Rahmadewi, R. (2025). Sistem Deteksi Jalan Berlubang Secara Real-Time Menggunakan Yolov11: Integrasi Data Dan Lokasi Melalui Website. *Jurnal JATI (Jurnal Mahasiswa Teknik Informatika)*, 9(3), 3953–3961. <https://doi.org/10.36040/jati.v9i3.13436>
- Jiang, Y. (2024). Road damage detection and classification using deep neural networks. *Discover Applied Sciences*, 6(8), 421. <https://doi.org/10.1007/s42452-024-06129-0>
- Joseph, A. K., Ashraf, D., Abraham, R., Thakadipurath, T. T., & Joseph, N. (2024). Revolutionizing Road Damage Assessment with YOLOv8-based Deep Learning and Computer Vision Techniques. *IEEE Xplore*, 1–6. <https://doi.org/10.1109/ICTEST60614.2024.10576192>
- Lyona, V., Putra, B. H. R., MG, I. M., & Prakasa, R. R. (2025). Analisis Tingkat Kerusakan Jalan di Lingkungan Kampus Universitas Riau Menggunakan Surface Distress Index (SDI). *Jurnal JICE -Journal of Infrastructure and Civil Engineering*, 5(2), 149–156. <https://doi.org/10.35583/jice.v5i2.128>
- Mulyana, D. I., & Wahyudi, I. (. (2025). Deteksi Kerusakan Jalan Berdasarkan Citra Digital Menggunakan Convolutional Neural Network (CNN). *Jurnal Indonesia : Manajemen Informatika Dan Komunikasi*, 6(1), 294–302. <https://doi.org/10.35870/jimik.v6i1.1192>
- Munadi, M. (2025). (2025). Penerapan Algoritma Deep Learning untuk Deteksi Dini Penyakit dari Citra Medis. *Journal of Computer Science and Information Technology*, 1(2), 53–59. <https://doi.org/10.70716/jocsit.v1i2.259>
- Ranyal, E., Sadhu, A., & Jain, K. (2022). Road Condition Monitoring Using Smart Sensing and Artificial Intelligence: A Review. *Sensors*, 22(8), 1–27. <https://doi.org/10.3390/s22083044>
- Ren, M., Zhang, X., Chen, X., Zhou, B., & Feng, Z. (2023). International Journal of Applied Earth Observation and Geoinformation YOLOv5s-M : A deep learning network model for road pavement damage detection from urban street-view imagery. *International Journal of Applied Earth Observation and Geoinformation*, 120(May), 103335. <https://doi.org/10.1016/j.jag.2023.103335>
- Ruseruka, C., Mwakalonge, J., Comert, G., Siuhi, S., & Perkins, J. (2023). Road Condition Monitoring Using Vehicle Built-in Cameras and GPS Sensors : A Deep Learning Approach. *Vehicles*, 5(3), 931–948. <https://doi.org/10.3390/vehicles5030051>
- Samsinar, R., Isyanto, H., Almanda, D., & Amrullah, F. (2024). Sistem Monitoring Mendeteksi Mata Lelah Pada Pengemudi Kendaraan Besar Berbasis Pengolahan Citra. *Jurnal RESISTOR (Elektronika Kendali Telekomunikasi Tenaga Listrik Komputer)*, 7(1), 77–84. <https://doi.org/10.24853/resistor.7.1.77-84>
- Saputra, E., Parianta, A., & Mahendra, M. O. (2025). Strategi Pemeliharaan Dan Model Hubungan Antara Nilai Kekasaran Jalan Dan Nilai Kondisi Perkerasan Kaku Dengan Metode IKP Dan IRI Studi Kasus Jalan Lingkar Selatan Kota Cilegon. *Prosiding Seminar Nasional Rekayasa Dan Teknologi*, 5(1), 40–46. <https://doi.org/10.47970/snarstek.v2i1.768>

- Sasmito, B., Setiadji, B. H., & Isnanto, R. (2023). Deteksi Kerusakan Jalan Menggunakan Pengolahan Citra Deep Learning di Kota Semarang. *Jurnal Ilmiah Bidang Ilmu Kerekayasaan*, 44(1), 7–14. <https://doi.org/10.14710/teknik.v44i1.51908>
- Sofiani, A. I., Hervy, N. E., Lestari, F. D., Putra, M. R. A., Putri, M. F., Khaira, U., & Utomo, P. E. P. (2025). Penerapan Model YOLO Untuk Deteksi Kerusakan Jalan Berdasarkan Citra Visual. *MATHunesa: Jurnal Ilmiah Matematika*, 13(3), 196–204. <https://doi.org/10.26740/mathunesa.v13n3.p196-204>
- Sunardi, N. A., Natsir, R., & Fikri, M. (2025). Evaluasi Kondisi Permukaan Jalan Dengan Metode Road Condition Index (RCI) dan Surface Distress Index (SDI): Studi Kasus: Jalan Pelabuhan Munte, Desa Rampoang, Kecamatan Tana Lili, Kabupaten Luwu Utara. *Jurnal Ilmiah Ecosystem*, 25(3), 612–625. <https://doi.org/10.35965/eco.v25i3.7960>
- Sutisna, T., Raharja, A. R., Solihin, S., Hariyadi, E., & Putra, V. H. C. (2024). Penggunaan Computer Vision untuk Menghitung Jumlah Kendaraan dengan Menggunakan Metode SSD (Single Shoot Detector). *Jurnal INNOVATIVE: Journal Of Social Science Research*, 4(2), 6060–6067. <https://doi.org/10.31004/innovative.v4i2.10071>
- Takyudin, T., Rais, M. S., Putra, J. A., & Hamsar, A. (2025). Metode Deteksi dan Estimasi Luas Lubang Jalan Menggunakan Deep Learning Berbasis YOLOv11. *Journal of Artificial Intelligence and Digital Business*, 4(2), 6786–6790. <https://doi.org/10.31004/riggs.v4i2.1760>
- Thakur, R., Kumar, P., & Thakur, P. (2025). YOLOv8-based Pothole Detection : A Real-time Approach for Road Infrastructure Monitoring. *International Conference on Optimization Techniques in the Field of Engineering (ICOFE-2024)*.
- Urbiztondo, M., Wu, M., & Kwon, T. J. (2025). Transportation Research Interdisciplinary Perspectives Advancing winter road maintenance : An AI-driven web platform for real-time road condition monitoring and spatial analysis. *Transportation Research Interdisciplinary Perspectives*, 33, 101575. <https://doi.org/10.1016/j.trip.2025.101575>
- Zhan, W. (2024). Application and Optimization of Computer Vision and Deep Learning in Road and Bridge Structure Monitoring. *Third International Conference on Distributed Computing and Electrical Circuits and Electronics (ICDCECE)*, 1–6. <https://doi.org/10.1109/ICDCECE60827.2024.10549690>
- Zhang, S., Liu, Z., Wang, K., Huang, W., & Li, P. (2025). OBC-YOLOv8 : an improved road damage detection model based on YOLOv8. *PeerJ Computer Science*, 11, e2593. <https://doi.org/10.7717/peerj-cs.2593>
- Zhao, Y., Shi, B., Duan, X., Zhu, W., Ren, L., & Liao, C. (2025). Research on road surface damage detection based on SEA-YOLO v8. *PloS One*, 20(6), 1–26. <https://doi.org/10.1371/journal.pone.0324439>

LAMPIRAN

Lampiran 1. Perhitungan Kelas *Pothole*

Pothole:

$$Precision_{pothole} = \frac{200}{200 + 46} = \frac{200}{246} = 0,8130 = 81,30\%$$

$$Recall_{pothole} = \frac{200}{200 + 73} = \frac{200}{273} = 0,7326 = 73,26\%$$

$$F1-Score_{pothole} = \frac{2 \times 0,8130 \times 0,7326}{0,8130 + 0,7326} = \frac{1,1912}{1,5456} = 0,7708 = 77,08\%$$

Lampiran 2. Perhitungan Kelas *Alligator Crack*

Alligator Crack:

$$Precision_{alligator} = \frac{68}{68 + 42} = \frac{68}{110} = 0,6182 = 61,82\%$$

$$Recall_{alligator} = \frac{68}{68 + 51} = \frac{68}{119} = 0,5714 = 57,14\%$$

$$F1-Score_{alligator} = \frac{2 \times 0,6182 \times 0,5714}{0,6182 + 0,5714} = \frac{0,7066}{1,1896} = 0,5939 = 59,39\%$$

Lampiran 3. Perhitungan Kelas *Linear Crack*

Linear Crack:

$$Precision_{linear} = \frac{123}{123 + 83} = \frac{123}{206} = 0,5971 = 59,71\%$$

$$Recall_{linear} = \frac{123}{123 + 116} = \frac{123}{239} = 0,5146 = 51,46\%$$

$$F1-Score_{linear} = \frac{2 \times 0,5971 \times 0,5146}{0,5971 + 0,5146} = \frac{0,6146}{1,1117} = 0,5529 = 55,29\%$$

Lampiran 4. Tabel Laporan

<i>Field</i>	Tipe Data	Keterangan
id_laporan	INT (PK)	ID laporan
email	VARCHAR(100)	Email Pelapor
tanggal	DATETIME	Waktu laporan
latitude	FLOAT	Koordinat latitude
longitude	FLOAT	Koordinat longitude
gambar	TEXT	Path/URL gambar
rds_score	FLOAT	Nilai <i>Road Damage Score</i>

Lampiran 5. Tabel Deteksi

<i>Field</i>	Tipe Data	Ketrangan
id_deteksi	INT (PK)	ID deteksi
id_laporan	INT(FK)	Relasi ke laporan
kelas	VARCHAR (50)	Jenis kerusakan
confidence score	FLOAT	Nilai confidence YOLO
bbox_x	FLOAT	Koordinat x
bbox_y	FLOAT	Koordinat Y
bbox_width	FLOAT	Lebar <i>bounding box</i>
bbox_height	FLOAT	Tinggi <i>bounding box</i>